

# UNM

## Linearni sistemi

NORME:  $\|A\|_1 = \max_{j \in \{1..n\}} (\sum_{i=1}^n |a_{ij}|) =$  največji stolpec,  $\|A\|_\infty = \|A^T\|_1 =$  največja vrstica  
 $\|A\|_2 = \sigma_1 = \sqrt{\lambda_{\max}(A^H A)} =$  največja singularna vrednost,  $\|A\|_F = \sqrt{\sum_{ij} a_{ij}^2} =$  gledamo kot vektor  
Operatorska norma:  $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$ . Neenakosti:  $\lambda \leq \|A\|$ .  $\|Ax\| \leq \|A\| \|x\|$ .

$$\begin{aligned} \frac{1}{\sqrt{n}} \|A\|_F &\leq \|A\|_2 \leq \|A\|_F \\ \frac{1}{\sqrt{n}} \|A\|_1 &\leq \|A\|_2 \leq \sqrt{n} \|A\|_1 \\ \frac{1}{\sqrt{n}} \|A\|_\infty &\leq \|A\|_2 \leq \sqrt{n} \|A\|_\infty \\ N_\infty(A) &\leq \|A\|_2 \leq n N_\infty(A) \\ &\leq \|A\|_2 \leq \sqrt{\|A\|_1 \|A\|_\infty} \\ \|a_i\|_2, \|\alpha_i\|_2 &\leq \|A\|_2 \end{aligned}$$

Rešujemo sistem  $Ax = b$ . Za napako  $x$  velja ocena:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\Delta A\|}{\|A\|}} \left( \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right)$$

Količina  $\kappa(A)$  se imenuje občutljivost matrike.  $\kappa(A) = \|A\| \|A^{-1}\|$ . Velja  $\kappa_2(A) = \frac{\sigma_1(A)}{\sigma_n(A)} \geq 1$ .

LU RAZCEP s kompletnim pivotiranjem: matriko  $A$  zapišemo kot  $PAQ = UL$ ,  $L$  sp. trikotna z 1 na diagonali in  $U$  zg. trikotna, ter  $P, Q$  permutacijski matriki stolpcev in vrstic. Algoritem:

```
Q = I, P = I
for j = 1 to n:
  r, q taka, da a_rq največji v podmatriki A(j+1:n)
  zamenjaj vrstici r in j v A, L, P // za delno pivotiranje
  zamenjaj stolpca q in j v A, L, Q // za kompletno pivotiranje
  for i = j+1 to n:
    l_ij = a_ij / a_jj
    for k = j+1 to n:
      a_ik = a_ik - l_ij * a_jk
```

Postopek na roke:

1. \* Če delamo pivotiranje zamenjamo primerne vrstice in stolpce v  $A, P, Q$ , da je  $a_{00}$  največji.
2. Prvi stolpec delimo z  $a_{00}$ , razen  $a_{00}$ , ki ga pustimo na miru.
3. Za vsak element v podmatriki  $A(2:n, 2:n)$ :  $a_{ij} = a_{ij} - a_{i1} \cdot a_{1j}$  (odštejemo produkt  $\leftarrow$  in  $\uparrow$ ).
4. Ponovimo postopek na matriki  $A(2:n, 2:n)$ .

Delno pivotiranje uporablja samo matriko  $P$ , za LU razcep brez pivotiranja pa preskočimo 1.

Skalarni produkt potrebuje  $2n$  operacij. Reševanje s premimi substitucijami potrebuje  $n^2$ , z obratnimi  $n^2 + n$ . Reševanje z LU razcepom (brez pivotiranja) potrebuje  $\frac{2}{3}n^3 + \frac{3}{2}n^2 + \frac{5}{6}n$  operacij.

Za izračunani LU razcep  $\hat{L}\hat{U} = A + E$  velja  $|E| \leq nu|\hat{L}||\hat{U}|$ .

Pivotna rast:  $g = \frac{\max u_{ij}}{\max a_{ij}}$ . Pri delnem pivotiranju  $g < 2^n$ .

RAZCEP CHOLESKEGA: Za spd matriko  $A$  obstaja razcep  $A = VV^T$ .

```
for k = 1 to n:
  v_kk = sqrt(a_kk - sum(v_kj^2, j=1 to k))
  for i = k+1 to n:
    v_ik = 1/v_kk * (a_ik - sum(v_ij * v_kj, j = 1 to k))
```

Postopek na roke po stolpcih:

1. Če sem diagonalen element: odštejem od sebe skalarni produkt vrstice na levo same s sabo in se korenim.
2. Če nisem diagonalni: od sebe odštejem skalarni produkt vrstice levo od sebe z vrstico levo od mojega diagonalnega. Nato se delim z diagonalnim.

Razcep stane  $\frac{1}{3}n^3$  operacij. Je obratno stabilno. Je enoličen.

## Nelinearni sistemi

JACOBIJEVA ITERACIJA: Posplošitev navadne iteracije. Naj velja  $G(\alpha) = \alpha$ . Metoda:  $x^{(r+1)} = G(x^{(r)})$ . Točka  $\alpha$  je privlačna, če velja  $\rho(DG(\alpha)) < 1$ . Dovolj je  $\|DG(\alpha)\| < 1$ . Konvergenca je linearna.

NEWTONOVA METODA: Posplošitev tangentne metode. Metoda: reši sistem  $DF(x^{(r)})\Delta x^{(r)} = -F(x^{(r)})$ .  $x^{(r+1)} = x^{(r)} + \Delta x^{(r)}$ . Konvergenca je kvadratična.

## Problem najmanjših kvadratov

REŠEVANJE PREDOLOČENIH SISTEMOV: Za dan predoločen sistem  $Ax = b$  rešujemo normalni sistem  $A^T Ax = A^T b$ . Če je  $A$  polnega ranga, je  $x$  enoličen. Rešujemo z razcepom Choleskega. Število operacij:  $n^2 m + \frac{1}{3} n^3$ .

QR razcep je bolj stabilen. Za  $A \in \mathbb{R}^{m \times n}$  obstaja enoličen razcep  $A = QR$ ,  $Q^T Q = I$  in  $R$  zg. trikotna s pozitivnimi diagonalci. Za predoločen sistem rešimo  $Rx = Q^T b$ .

CGS IN MGS Klasična GS ortogonalizacija. Od vsakega stolpca  $a_k$  odštejemo pravokotne projekcije  $a_i, i < k$ . Algoritem ni najbolj stabilen.

```
for k = 1 to n:
  q_k = a_k
  for i = 1 to k-1:
    r_ik = q_i' * a_k (CGS) ALI = q_i' * q_k (MGS)
    q_k = q_k - r_ik q_i
  r_kk = ||q_k||
  q_k = q_k / r_kk
```

Za večjo natančnost izračunamo  $[Ab] = [Qq_{n+1}][Rz; 0p]$  in rešimo  $Rx = z$ . Porabi  $2nm^2$  operacij.

Razširjeni QR razcep:  $A = \tilde{Q}\tilde{R}$ ,  $Q \in \mathbb{R}^{m \times m}$  ortogonalna,  $R$  zgornje trapezna.  $\tilde{Q} = [Q \ Q_1]$ ,  $\tilde{R} = [R; 0]$ .

### GIVENSOVE ROTACIJE

Elemente v  $A$  po stolpcih enega po enega ubijamo z rotacijami. Rotacija, ki ubije element  $a_{ki}$  je  $R_{ik}^T([ik], [i, k]) = [c \ s; -s \ c]$ , in ostalo identiteta. Parametre nastavimo:  $c = x_{ii}/r$ ,  $s = x_{ki}/r$ ,  $r = \sqrt{x_{ii}^2 + x_{ki}^2}$ .  $\tilde{Q}$  dobimo kot produkt vseh rotacij, potrebnih za genocid elementov  $A$ . Rotacija spremeni samo  $i$ -to in  $k$ -to vrstico.

Število operacij:  $3mn^2 - n^3$ . Če potrebujemo  $\tilde{Q}$ , potem rabimo še dodatnih  $6m^2 n - 3mn^2$  operacij.

```
Q = I_m
for i = 1 to n:
  for k = i+1 to m:
    r = sqrt(a_ii^2 + a_ki^2)
    c = a_ii/r, s = a_ki/r
    A([i,k], i:n) = [c s; -s c] A([i k], i:n)
    b([i, k]) = [c s; -s c] b([i, k]) // za predoločen sistem
    Q(i, [i k]) = Q(i, [i k]) [c -s; s c] // za matriko Q
Q = Q'
```

HAUSHOLDERJEVA ZRCALJENJA Definiramo  $P = I - \frac{2}{w^T w} w w^T$ .  $P$  je zrcaljenje prek ravnine z normalo  $w$ .  $Px = x - \frac{1}{m}(x^T w)w$ ,  $m = \frac{1}{2} w^T w$ .

Da vektor  $x$  prezrcalimo tako, da mu uničimo vse razen prve komponente, uporabimo  $w = [x_1 + \text{sign}(x_1)\|x\|_2; x_2; \dots x_n]$  in  $m = \|x\|_2(\|x\|_2 + |x_1|)$ . Število operacij za  $Pz$  je  $4nm$  za  $w$  in  $m$  pa potrebujemo  $2n$  operacij.

```
Q = I_m
for i = 1 to n:
  w_i iz R^{m-i+1}, ki prezrcali A(i:m, i) v +-k e_1
  A(i:m, i:n) = P_i * A(i:m, i:n)
  b(i:m) = P_i * b(i:m) // za predoločen sistem
  Q(i:m, i:n) = P_i * Q(i:m, i:n) // za matriko Q
Q = Q'
```

Reševanje predoločenega sistema tako stane  $2mn^2 - \frac{2}{3}n^3$ . Za  $\tilde{Q}$  potrebujemo še  $4m^2 n - 2mn^2$  operacij. Za kvadratne sisteme je stabilnejši, a rabimo  $\frac{4}{3}n^3$  operacij.

Za napako pri reševanju predoločenega sistema velja:  $\frac{\|\Delta x\|}{\|x\|} \leq \frac{\varepsilon \kappa_2(A)}{1 - \varepsilon \kappa_2(A)} \left( 2 + (\kappa_2(A) + 1) \frac{\|r\|}{\|A\| \|x\|} \right), r = Ax - b$ .

## Lastne vrednosti

Desni in levi lastni vektorji:  $y^H A = \mu y^H$  in  $Ax = \lambda x$ . Levi in desni vektorji za različne l. vrednosti so pravokotni. Občutljivost lastne vrednosti je  $\frac{1}{y^H x}$ , kjer sta  $x$  in  $y$  normirana levi in desni lastni vektor.

POTENČNA METODA: Pravzaprav navadna iteracija. Izberemo si začetni vektor  $z$  in tolčemo čez matriko  $A$  in normiramo, dokler ne postane lastni vektor. Ta metoda ima linearno konvergenco k lastnemu vektorju za dominantno

lastno vrednost, če je le ena sama lastna vrednost največja. Hitrost konvergence je  $\lambda_1/\lambda_2$ , kjer sta to dve največji lastni vrednosti.

```
z = ones(n, 1) // naključen neničeln vektor
for k = 1 to m: // m je veliko število
    y = A * z
    z = y / ||y||
```

Če imamo lastni vektor  $v$ , potem želimo imeti lastno vrednost  $\lambda$ . Najboljši približek je Raylegihov kvocient:  $\rho(A, v) = \frac{v^H A v}{v^H v}$ . Kot kriterij v potenčni metodi uporabimo  $|A * z - p(A, z)| < \text{eps}$ .

Če imamo dober približek  $\tilde{\lambda}$  za lastno vrednost vrednost  $\lambda_i$  uporabimo inverzno iteracijo. Iščemo največjo vrednost matrike  $(A - \tilde{\lambda}I)^{-1}$ , ki ima lastne vrednosti  $\frac{1}{\lambda_i - \tilde{\lambda}}$ .

```
z = ones(n, 1)
for k = 0 to m:
    reši (A - lambda I)y = z
    z = y / ||y||
```

**SCHUROVA FORMA:** Za vsako matriko  $A$  obstaja Schurova forma  $S$ , da je  $A = USU^H$ , kjer je  $U$  unitarna in  $S$  zgornje trikotna. Na diagonali so lastne vrednosti. V primeru kompleksnih lastnih vrednosti imamo  $2 \times 2$  bloke.

**OTROGONALNA ITERACIJA:** Za izračun Schurove forme.  $Z$  je lahko  $n \times p$  matrika z ortonormiranimi stolpci, tako dobimo prvih  $p$  stolpcev Schurove forme. Za  $p = 1$  je to potenčna metoda, za  $p = n$ , pa dobimo celo schurovo formo.

```
Z = eye(n) // naključna matrika z ortonormiranimi stolpci
for k = 0 to m:
    Y = A * Z
    [Q, R] = qr(Y)
    Z = Q
```

**QR ITERACIJA:** Najboljša metoda za izračun lastnih vrednosti  $A$ .

```
for k = 0 to m:
    [Q, R] = qr(A)
    A = R * Q
```

**GERSCGORINOV IZREK:** Naj bo  $A \in \mathbb{C}^{n \times n}$ ,  $C_i = \overline{K}(a_{ii}, r = \sum_{j=1, j \neq i}^n |a_{ij}|)$ ,  $i = 1, 2, \dots, n$ . Potem vsaka lastna vrednost leži v vsaj enem Gerschgorinovem krogu. Če  $m$  krogov  $C_i$  sestavlja povezano množico, ločeno od ostalih  $n - m$  krogov, potem ta množica vsebuje natanko  $m$  lastnih vrednosti.

Če množimo  $A$  z diagonalno matriko  $D$  (ponavadi le en element na diagonali različen od 1), torej  $D - 1AD$ , nam to ne spremeni lastnih vrednosti. Na novi matriki lahko ponovno uporabimo Gerschgorinov izrek in dobimo drugačne ocene.

Diagonalno dominantna matrika ( $|a_{ij}| > \sum_{j=1, j \neq i}^n |a_{ij}|$ ) je obrnljiva.

## NLA

### Singularni razcep

$A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ . Singularni razcep je razcep matirke  $A$  na  $A = U \Sigma V^T$ ,  $U$  ortogonalna  $m \times m$ ,  $V$  ortogonalna  $n \times n$ ,

$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \in \mathbb{R}^{m \times n}$ . Definiciji  $U$  in  $V$  po stolpcih:  $A^T A v_i = \sigma_i^2 v_i$ ,  $A v_i = \sigma_i u_i$ . Recimo da ima matrika

prvih  $r$  singularnih vrednosti neničelnih. Potem lahko  $V$  razdelimo na dva dela,  $V_1$  sestavljen iz lastnih vektorjev za neničelne lastne vrednosti  $A^T A$  in  $V_2$  sestavljen iz lastnih vektorjev za ničelno lastno vrednost. Bločno definiramo

$$A = \begin{bmatrix} m \times r & m \times m-r \end{bmatrix} \begin{bmatrix} r \times r & r \times n-r \\ m-r \times r & m-r \times n-r \end{bmatrix} \begin{bmatrix} r \times n \\ n-r \times n \end{bmatrix}$$

Definiramo lahko tudi ozek singularni razcep, pri katerem vzamemo samo  $U_1, S$  in  $V_1$ . Velja:

- $V_1$  je ONB za  $\text{im}(A^T)$
- $V_2$  je ONB za  $\text{ker}(A)$
- $U_1$  je ONB za  $\text{im}(A)$
- $U_2$  je ONB za  $\text{ker}(A^T)$

Pseudoinverz:  $A^+ = V\Sigma^+U^\top$ ,  $\Sigma^+ = [1/\sigma_i]_i$ . Rešitev po metodi najmanjših kvadratov:  $x = \sum_{i=1}^n \frac{u_i^\top b}{\sigma_i} v_i = A^+b$ .  
 Aproksimacija matrike z matriko nižjega ranga:  $A_k = \sum_{i=1}^k \sigma_i u_i v_i^\top$ .

Regularizacija: Pozabimo na manjše sing vrednosti, ki povzročajo napake.  $x = \sum_{i=1}^n \phi_i \frac{u_i^\top b}{\sigma_i} v_i$ , za  $\phi_i = (i \leq k)$  ali  $\phi_i = \frac{\sigma_i^2}{\sigma_i^2 + \alpha^2}$ .

Totalni najmanjši kvadrati: rešitev predoločenega sistema  $Ax = b$ , kjer poiščemo najbližji par  $[\tilde{A}, \tilde{b}]$ , da  $x$  reši sistem  $\tilde{A}x = \tilde{b}$ .  $x$ , ki reši ta sistem dobimo kot:  $x_{\text{TLS}} = \frac{-1}{v'_{n+1, n+1}} [v'_{1, n+1} \ \dots \ v'_{n, n+1}]^\top$ .

Nelinearne probleme najmanjših kvadratov:  $F(x) = 0$ , rešitev je  $x$ , ki minimizira  $\|F(x)\|_2$ . Rešujemo z Newtonovo metodo:  $x_{r+1} = x_r - J_F^\top(x_r)F(x_r)$ .

## Nesimetričen problem lastnih vrednosti

### Implicitni QR

Najprej reduciramo  $A$  na zg. Hessenbergovo. Nato  $A$  z leve in desne množimo z ortogonalnimi transformacijami  $Q$ , dokler ne skonvergira do shurove forme. Pomaga nam izrek o implicitnem  $Q$ .

Izrek: Če je  $Q = [q_1, \dots, q_n]$  taka ortogonalna matrika, da je  $H = Q^\top A Q$  zg. Hessenbergova, je  $Q$  do predznaka natančno določena s  $q_1$ .

Ko imamo  $A$  zg. Hessengergovo jo pomnožimo z leve z Givensovo rotacijo  $\tilde{R}$ , ki ima prvi stolpec enak normiranemu prvemu stolpcu  $A_k - \sigma_k I$ . S tem smo zagotovili, da ima naš  $Q$  s katerim množimo pravilen prvi stolpec (kot bi delali Gram-Schidta ali QR razcep). Da ohranimo podobnost, pomnožimo še z desne. Pojavi se grba, ki jo z rotacijami izženemo iz matrike in s tem naredimo en korak. Ponavljamo dokler niso vsi pod diagonalo mrtvi.

$$\begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\tilde{R}^\top} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\cdot \tilde{R}} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ + & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{R_{23}^\top} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{\cdot R_{23}} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & + & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{R_{34}^\top} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & + & * & * \\ & & & * & * \end{bmatrix}$$

Dvojni premiki: Prvo podobnostno transformacijo  $\tilde{P}$  izberemo, da bo imela enak prvi stolpec kot pri navadni QR, to je enak kot matrika  $N_k = A_k^2 - \text{sl}(S_k)A_k + \det(S_k)I$ , kjer je  $S_k$  spodnja  $2 \times 2$  matrika matrike  $A_k$ .  $N_k$  ima v prvem stolpcu samo 3 elemente neničljne, zato dobimo grbo velikosti 2 in delamo s Hausholderjevimi zrcaljenji  $3 \times 3$ . To so simetrične matrike, zato ni treba transponirati.

$$\begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\tilde{P} \cdot} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ + & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{\cdot \tilde{P}} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ + & * & * & * & * \\ + & + & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{P_2 \cdot} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{\cdot P_2} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & + & * & * \\ & & & + & * \end{bmatrix} \xrightarrow{P_3 \cdot} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & + & * & * \\ & & & + & * \end{bmatrix}$$

## Posplošeni problem lastnih vrednosti

Množico vseh matrik oblike  $A - \lambda B$  imenujemo matrični šop. Karakteristični polinom šopa  $(A, B)$  je  $p(\lambda) = \det(A - \lambda B)$ . Če je  $p$  identično enak 0, je šop singularen, sicer je regularen. Če je šop regularen in velja  $Ax = \lambda Bx$  za nek  $x \neq 0$ , je  $\lambda$  lastna vrednost in  $x$  desni lastni vektor. Če za regularen šop velja  $Bx = 0$  za nek  $x \neq 0$  je  $\lambda = \infty$  lastna vrednost šopa in  $x$  pripadajoči desni lastni vektor. Simetrično velja za leve lastne vektorje.

Če je karakteristični polinom šopa  $(A, B)$  stopnje  $m \leq n$  ima šop  $m$  lastnih vrednosti, ki so rešitve  $p(\lambda) = 0$  in neskončno lastno vrednost z večkratnostjo  $n - m$ .

Če je  $B$  nesingularna, so vse lastne vrednosti končne in so enake lastnim vrednostim matrik  $B^{-1}A$  in  $AB^{-1}$ . Neskončna lastna vrednost se pojavi, ko je  $B$  singularna, in njena večkratnost je enaka  $\dim(\ker(B))$ . Če je  $A$  singularna, si lastne vrednosti šopa enake recipročnim lastnim vrednostim  $A^{-1}B$  in  $BA^{-1}$  (lastna vrednost 0 pomeni, da ima šop lastno vrednost  $\infty$ )

Za primer lastnih frekvenc nihanja  $| -///k_1///-[m_1]-///k_2///-[m_2]-///k_3///-[m_3]-///k_4///-|$  zapišemo

$M = \text{diag}(m_1, m_2, m_3)$ ,

$K = \begin{bmatrix} k_1 + k_2 & -k_2 & & \\ -k_2 & k_2 + k_3 & -k_3 & \\ & -k_3 & k_3 + k_4 & \end{bmatrix}$  rešujemo sistem  $\omega^2 M y + K y = 0$ , kar lahko prevedemo na  $M^{-1} K y = \lambda y$ ,  $\lambda = \omega^2$

## Sturmovo zaporedje

Matrika  $T$  je tridiagonalna ( $\text{diag}(a_1, \dots, a_n) + \text{diag}(b_1, \dots, b_{n-1}, 1) + \text{diag}(b_1, \dots, b_{n-1}, -1)$ )

$$f_0(\lambda) = 1, f_1(\lambda) = a_1 - \lambda, f_{k+1}(\lambda) = (a_{k+1} - \lambda)f_k(\lambda) - b_k^2 f_{k-1}(\lambda)$$

Zapišemo zaporedje  $f(x)$ , preštejemo kolikokrat se predznak zamenja (+ 0 – in – 0 + šteje za eno zamenjavo, če je 0 na koncu ne upoštevamo kot zamenjava). Kolikor je menjav predznaka, toliko je lastnih vrednosti na  $(x, \infty)$ .