

# UNM

## Linearni sistemi

NORME:  $\|A\|_1 = \max_{j \in \{1..n\}} (\sum_{i=1}^n |a_{ij}|) =$  največji stolpec,  $\|A\|_\infty = \|A^T\|_1 =$  največja vrstica  
 $\|A\|_2 = \sigma_1 = \sqrt{\lambda_{\max}(A^H A)} =$  največja singularna vrednost,  $\|A\|_F = \sqrt{\sum_{ij} a_{ij}^2} =$  gledamo kot vektor  
Operatorska norma:  $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$ . Neenakosti:  $\lambda \leq \|A\|$ .  $\|Ax\| \leq \|A\| \|x\|$ .

$$\begin{aligned} \frac{1}{\sqrt{n}} \|A\|_F &\leq \|A\|_2 \leq \|A\|_F \\ \frac{1}{\sqrt{n}} \|A\|_1 &\leq \|A\|_2 \leq \sqrt{n} \|A\|_1 \\ \frac{1}{\sqrt{n}} \|A\|_\infty &\leq \|A\|_2 \leq \sqrt{n} \|A\|_\infty \\ N_\infty(A) &\leq \|A\|_2 \leq n N_\infty(A) \\ &\leq \|A\|_2 \leq \sqrt{\|A\|_1 \|A\|_\infty} \\ \|a_i\|_2, \|\alpha_i\|_2 &\leq \|A\|_2 \end{aligned}$$

Rešujemo sistem  $Ax = b$ . Za napako  $x$  velja ocena:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\Delta A\|}{\|A\|}} \left( \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right)$$

Količina  $\kappa(A)$  se imenuje občutljivost matrike.  $\kappa(A) = \|A\| \|A^{-1}\|$ . Velja  $\kappa_2(A) = \frac{\sigma_1(A)}{\sigma_n(A)} \geq 1$ .

LU RAZCEP s kompletnim pivotiranjem: matriko  $A$  zapišemo kot  $PAQ = UL$ ,  $L$  sp. trikotna z 1 na diagonali in  $U$  zg. trikotna, ter  $P, Q$  permutacijski matriki stolpcev in vrstic. Algoritem:

```
Q = I, P = I
for j = 1 to n:
  r, q taka, da a_rq največji v podmatriki A(j+1:n)
  zamenjaj vrstici r in j v A, L, P // za delno pivotiranje
  zamenjaj stolpca q in j v A, L, Q // za kompletno pivotiranje
  for i = j+1 to n:
    l_ij = a_ij / a_jj
    for k = j+1 to n:
      a_ik = a_ik - l_ij * a_jk
```

Skalarni produkt potrebuje  $2n$  operacij. Reševanje s premimi substitucijami potrebuje  $n^2$ , z obratnimi  $n^2 + n$ . Reševanje z LU razcepom (brez pivotiranja) potrebuje  $\frac{2}{3}n^3 + \frac{3}{2}n^2 + \frac{5}{6}n$  operacij. Za izračunani LU razcep  $\hat{L}\hat{U} = A + E$  velja  $|E| \leq nu|\hat{L}||\hat{U}|$ . Pivotna rast:  $g = \frac{\max u_{ij}}{\max a_{ij}}$ . Pri delnem pivotiranju  $g < 2^n$ .

RAZCEP CHOLESKEGA: Za spd matriko  $A$  obstaja razcep  $A = VV^T$ .

```
for k = 1 to n:
  v_kk = sqrt(a_kk - sum(v_kj^2, j=1 to k))
  for i = k+1 to n:
    v_ik = 1/v_kk * (a_ik - sum(v_ij * v_kj, j = 1 to k))
```

Razcep stane  $\frac{1}{3}n^3$  operacij. Je obratno stabilno. Je enoličen.

## Nelinearni sistemi

JACOBIJEVA ITERACIJA: Posplošitev navadne iteracije. Naj velja  $G(\alpha) = \alpha$ . Metoda:  $x^{(r+1)} = G(x^{(r)})$ . Točka  $\alpha$  je privlačna, če velja  $\rho(DG(\alpha)) < 1$ . Dovolj je  $\|DG(\alpha)\| < 1$ . Konvergenca je linearna.

NEWTONOVA METODA: Posplošitev tangentne metode. Metoda: reši sistem  $DF(x^{(r)})\Delta x^{(r)} = -F(x^{(r)})$ .  $x^{(r+1)} = x^{(r)} + \Delta x^{(r)}$ . Konvergenca je kvadratična.

## Problem najmanjših kvadratov

REŠEVANJE PREDOLOČENIH SISTEMOV: Za dan predoločen sistem  $Ax = b$  rešujemo normalni sistem  $A^T Ax = A^T b$ . Če je  $A$  polnega ranga, je  $x$  enoličen. Rešujemo z razcepom Choleskega. Število operacij:  $n^2 m + \frac{1}{3}n^3$ .

QR razcep je bolj stabilen. Za  $A \in \mathbb{R}^{m \times n}$  obstaja enoličen razcep  $A = QR$ ,  $Q^T Q = I$  in  $R$  zg. trikotna s pozitivnimi diagonalci. Za predoločen sistem rešimo  $Rx = Q^T b$ .

CGS IN MGS Klasična GS ortogonalizacija. Od vsakega stolpca  $a_k$  odštejemo pravokotne projekcije  $a_i, i < k$ . Algoritem ni najbolj stabilen.

```

for k = 1 to n:
  q_k = a_k
  for i = 1 to k-1:
    r_ik = q_i' * a_k (CGS) ALI = q_i' * q_k (MGS)
    q_k = q_k - r_ik q_i
  r_kk = ||q_k||
  q_k = q_k / r_kk

```

Za večjo natančnost izračunamo  $[Ab] = [Qq_{n+1}][Rz; 0p]$  in rešimo  $Rx = z$ . Porabi  $2nm^2$  operacij.

Razširjeni QR razcep:  $A = \tilde{Q}\tilde{R}$ ,  $Q \in \mathbb{R}^{m \times m}$  ortogonalna,  $R$  zgornje trapezna.  $\tilde{Q} = [Q \ Q_1]$ ,  $\tilde{R} = [R; 0]$ .

#### GIVENSOVE ROTACIJE

Elemente v  $A$  po stolpcih enega po enega ubijamo z rotacijami. Rotacija, ki ubije element  $a_{ki}$  je  $R_{ik}^T([ik], [i, k]) = [c \ s; -s \ c]$ , in ostalo identiteta. Parametre nastavimo:  $c = x_{ii}/r$ ,  $s = x_{ki}/r$ ,  $r = \sqrt{x_{ii}^2 + x_{ki}^2}$ .  $\tilde{Q}$  dobimo kot produkt vseh rotacij, potrebnih za genocid elementov  $A$ . Rotacija spremeni samo  $i$ -to in  $k$ -to vrstico.

Število operacij:  $3mn^2 - n^3$ . Če potrebujemo  $\tilde{Q}$ , potem rabimo še dodatnih  $6m^2n - 3mn^2$  operacij.

```

Q = I_m
for i = 1 to n:
  for k = i+1 to m:
    r = sqrt(a_ii^2 + a_ki^2)
    c = a_ii/r, s = a_ki/r
    A([i,k], i:n) = [c s; -s c] A([i k], i:n)
    b([i, k]) = [c s; -s c] b([i, k]) // za predoločen sistem
    Q(i, [i k]) = Q(i, [i k]) [c -s; s c] // za matriko Q
Q = Q'

```

HAUSHOLDERJEVA ZRCALJENJA Definiramo  $P = I - \frac{2}{w^T w} w w^T$ .  $P$  je zrcaljenje prek ravnine z normalo  $w$ .  $Px = x - \frac{1}{m}(x^T w)w$ ,  $m = \frac{1}{2}w^T w$ .

Da vektor  $x$  prezrcalimo tako, da mu uničimo vse razen prve komponente, uporabimo  $w = [x_1 + \text{sign}(x_1)\|x\|_2; x_2; \dots x_n]$  in  $m = \|x\|_2(\|x\|_2 + |x_1|)$ . Število operacij za  $Pz$  je  $4nm$  za  $w$  in  $m$  pa potrebujemo  $2n$  operacij.

```

Q = I_m
for i = 1 to n:
  w_i iz R^{m-i+1}, ki prezrcali A(i:m, i) v +-k e_1
  A(i:m, i:n) = P_i * A(i:m, i:n)
  b(i:m) = P_i * b(i:m) // za predoločen sistem
  Q(i:m, i:n) = P_i * Q(i:m, i:n) // za matriko Q
Q = Q'

```

Reševanje predoločenega sistema tako stane  $2mn^2 - \frac{2}{3}n^3$ . Za  $\tilde{Q}$  potrebujemo še  $4m^2n - 2mn^2$  operacij. Za kvadratne sisteme je stabilnejši, a rabimo  $\frac{4}{3}n^3$  operacij.

Za napako pri reševanju predoločenega sistema velja:  $\frac{\|\Delta x\|}{\|x\|} \leq \frac{\varepsilon \kappa_2(A)}{1 - \varepsilon \kappa_2(A)} \left( 2 + (\kappa_2(A) + 1) \frac{\|r\|}{\|A\| \|x\|} \right)$ ,  $r = Ax - b$ .

## Lastne vrednosti

Desni in levi lastni vektorji:  $y^H A = \mu y^H$  in  $Ax = \lambda x$ . Levi in desni vektorji za različne l. vrednosti so pravokotni. Občutljivost lastne vrednosti je  $\frac{1}{y^H x}$ , kjer sta  $x$  in  $y$  normirana levi in desni lastni vektor.

POTENČNA METODA: Pravzaprav navadna iteracija. Izberemo si začetni vektor  $z$  in tolčemo čez matriko  $A$  in normiramo, dokler ne postane lastni vektor. Ta metoda ima linearno konvergenco k lastnemu vektorju za dominantno lastno vrednost, če je le ena sama lastna vrednost največja. Hitrost konvergence je  $\lambda_1/\lambda_2$ , kjer sta to dve največji lastni vrednosti.

```

z = ones(n, 1) // naključen neničeln vektor
for k = 1 to m: // m je veliko število
  y = A * z
  z = y / ||y||

```

Če imamo lastni vektor  $v$ , potem želimo imeti lastno vrednost  $\lambda$ . Najboljši približek je **Raylegihov kvocient**:  $\rho(A, v) = \frac{v^H A v}{v^H v}$ . Velja:  $\rho(\alpha x, A) = \rho(x, A)$ ,  $\rho(x_i, A) = \lambda_i$ , če  $x_i$  lastni vektor. Minimum  $\|Ax - \sigma x\|_2$  je dosežen pri  $\rho(x, A)$ . Kot kriterij v potenčni metodi uporabimo  $|A * z - p(A, z)| < \text{eps}$ .

Če imamo dober približek  $\tilde{\lambda}$  za lastno vrednost vrednost  $\lambda_i$  uporabimo inverzno iteracijo. Iščemo največjo vrednost matrike  $(A - \tilde{\lambda}I)^{-1}$ , ki ima lastne vrednosti  $\frac{1}{\lambda_i - \tilde{\lambda}}$ .

```

z = ones(n, 1)
for k = 0 to m:
  reši (A - lambda I)y = z
  z = y / ||y||

```

**SCHUROVA FORMA:** Za vsako matriko  $A$  obstaja Schurova forma  $S$ , da je  $A = USU^H$ , kjer je  $U$  unitarna in  $S$  zgornje trikotna. Na diagonali so lastne vrednosti. V primeru kompleksnih lastnih vrednosti imamo  $2 \times 2$  bloke.

**OTROGONALNA ITERACIJA:** Za izračun Schurove forme.  $Z$  je lahko  $n \times p$  matrika z ortonormiranimi stolpci, tako dobimo prvih  $p$  stolpcev Schurove forme. Za  $p = 1$  je to potenčna metoda, za  $p = n$ , pa dobimo celo schurovo formo.

```
Z = eye(n) // naključna matrika z ortonormiranimi stolpci
for k = 0 to m:
    Y = A * Z
    [Q, R] = qr(Y)
    Z = Q
```

**QR ITERACIJA:** Najboljša metoda za izračun lastnih vrednosti  $A$ .

```
for k = 0 to m:
    [Q, R] = qr(A)
    A = R * Q
```

**GERSCGORINOV IZREK:** Naj bo  $A \in \mathbb{C}^{n \times n}$ ,  $C_i = \overline{K}(a_{ii}, r = \sum_{j=1, j \neq i}^n |a_{ij}|)$ ,  $i = 1, 2, \dots, n$ . Potem vsaka lastna vrednost leži v vsaj enem Gerschgorinovem krogu. Če  $m$  krogov  $C_i$  sestavlja povezano množico, ločeno od ostalih  $n - m$  krogov, potem ta množica vsebuje natanko  $m$  lastnih vrednosti.

Če množimo  $A$  z diagonalno matriko  $D$  (ponavadi le en element na diagonali različen od 1), torej  $D^{-1}AD$ , nam to ne spremeni lastnih vrednosti. Na novi matriki lahko ponovno uporabimo Gerschgorinov izrek in dobimo drugačne ocene.

Diagonalno dominantna matrika ( $|a_{ij}| > \sum_{j=1, j \neq i}^n |a_{ij}|$ ) je obrnljiva.

## NLA

### Singularni razcep

$A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ . Singularni razcep je razcep matirke  $A$  na  $A = U\Sigma V^T$ ,  $U$  ortogonalna  $m \times m$ ,  $V$  ortogonalna  $n \times n$ ,

$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \in \mathbb{R}^{m \times n}$ . Definiciji  $U$  in  $V$  po stolpcih:  $A^T A v_i = \sigma_i^2 v_i$ ,  $A v_i = \sigma_i u_i$ . Recimo da ima matrika

prvih  $r$  singularnih vrednosti neničelnih. Potem lahko  $V$  razdelimo na dva dela,  $V_1$  sestavljen iz lastnih vektorjev za neničelne lastne vrednosti  $A^T A$  in  $V_2$  sestavljen iz lastnih vektorjev za ničelno lastno vrednost. Bločno definiramo

$$A = \begin{bmatrix} m \times r & m \times m-r \end{bmatrix} \begin{bmatrix} r \times r & r \times n-r \\ m-r \times r & m-r \times n-r \end{bmatrix} \begin{bmatrix} r \times n \\ n-r \times n \end{bmatrix}$$

Definiramo lahko tudi ozek singularni razcep, pri katerem vzamemo samo  $U_1, S$  in  $V_1$ . Velja:

- $V_1$  je ONB za  $\text{im}(A^T)$
- $V_2$  je ONB za  $\ker(A)$
- $U_1$  je ONB za  $\text{im}(A)$
- $U_2$  je ONB za  $\ker(A^T)$

Pseudoinverz:  $A^+ = V\Sigma^+ U^T$ ,  $\Sigma^+ = [1/\sigma_i]_i$ . Rešitev po metodi najmanjših kvadratov:  $x = \sum_{i=1}^n \frac{u_i^T b}{\sigma_i} v_i = A^+ b$ . Aproksimacija matrike z matriko nižjega ranga:  $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$ .

Regularizacija: Pozabimo na manjše sing vrednosti, ki povzročajo napake.  $x = \sum_{i=1}^n \phi_i \frac{u_i^T b}{\sigma_i} v_i$ , za  $\phi_i = (i \leq k)$  ali  $\phi_i = \frac{\sigma_i^2}{\sigma_i^2 + \alpha^2}$ .

Totalni najmanjši kvadrati: rešitev predoločenega sistema  $Ax = b$ , kjer poiščemo najbližji par  $[\tilde{A}, \tilde{b}]$ , da  $x$  reši sistem  $\tilde{A}x = \tilde{b}$ .  $x$ , ki reši ta sistem dobimo kot:  $x_{\text{TLS}} = \frac{-1}{v'_{n+1, n+1}} \begin{bmatrix} v'_{1, n+1} & \dots & v'_{n, n+1} \end{bmatrix}^T$ .

Nelinearne probleme najmanjših kvadratov:  $F(x) = 0$ , rešitev je  $x$ , ki minimizira  $\|F(x)\|_2$ . Rešujemo z Newtonovo metodo:  $x_{r+1} = x_r - J_F^+(x_r)F(x_r)$ .

## Nesimetričen problem lastnih vrednosti

### Implicitni QR

Najprej reduciramo  $A$  na zg. Hessenbergovo. Nato  $A$  z leve in desne množimo z ortogonalnimi transformacijami  $Q$ , dokler ne skonvergira do shurrove forme. Pomaga nam izrek o implicitnem  $Q$ .

Izrek: Če je  $Q = [q_1, \dots, q_n]$  taka ortogonalna matrika, da je  $H = Q^T A Q$  nerazcepna zg. Hessenbergova, je  $Q$  do predznaka natančno določena s  $q_1$ .

Ko imamo  $A$  zg. Hessengergovo jo pomnožimo z leve z Givensovo rotacijo  $\tilde{R}$ , ki ima prvi stolpec enak normiranemu prvemu stolpcu  $A_k - \sigma_k I$ . S tem smo zagotovili, da ima naš  $Q$  s katerim množimo pravičen prvi stolpec (kot bi delali Gram-Schidta ali QR razcep). Da ohranimo podobnost, pomnožimo še z desne. Pojavi se grba, ki jo z rotacijami izženemo iz matrike in s tem naredimo en korak. Ponavljamo dokler niso vsi pod diagonalo mrtvi.

$$\begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\tilde{R}^T} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\cdot \tilde{R}} \begin{bmatrix} * & * & * & * & * \\ + & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{R_{23}^T} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\cdot R_{23}} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & + & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{R_{34}^T} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & + & * & * \\ & & & * & * \\ & & & & * \end{bmatrix}$$

Dvojni premiki: Prvo podobnostno transformacijo  $\tilde{P}$  izberemo, da bo imela enak prvi stolpec kot pri navadni QR, to je enak kot matrika  $N_k = A_k^2 - \text{sl}(S_k)A_k + \det(S_k)I$ , kjer je  $S_k$  spodnja  $2 \times 2$  matrika matrike  $A_k$ .  $N_k$  ima v prvem stolpcu samo 3 elemente neničljne, zato dobimo grbo velikosti 2 in delamo s Hausholderjevimi zrcaljenji  $3 \times 3$ . To so simetrične matrike, zato ni treba transponirati.

$$\begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\tilde{P} \cdot} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ + & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{\cdot \tilde{P}} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ + & * & * & * & * \\ + & + & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \xrightarrow{P_2 \cdot} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \xrightarrow{\cdot P_2} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & + & + & * \\ & & & + & * \end{bmatrix} \xrightarrow{P_3 \cdot} \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & + & + & * \\ & & & + & * \end{bmatrix}$$

### Simetrični problem lastnih vrednosti

Matriko  $A = A^T$  lahko vedno diagonaliziramo in lastne vrednosti so realne. Lastni vektorji tvorijo ONB. Schurova forma je diagonalna.

Izrek: (o prepletanju) Naj bo  $A$   $n \times n$  simetrična matrika. Če je  $A_k$  vodilna  $k \times k$  podmatirka,  $k = 1, \dots, n-1$  velja:  $\lambda_{k+1}(A_{k+1}) \leq \lambda_k(A_k) \leq \lambda_k(A_{k+1}) \leq \dots \leq \lambda_2(A_{k+1}) \leq \lambda_1(A_k) \leq \lambda_1(A_{k+1})$ .

Izrek o inerciji: Če je  $A$  simetrična in  $X$  nesingularna potem imata  $X^T A X$  enako število pozitivnih, negativnih in ničelnih lastnih vrednosti.

Metode za izračun lastnih vrednosti:

Inverzna iteracija (zgoraj), če imamo približek za lastno vrednost in želimo lastni vektor.

Rayleighova iteracija, če imamo približek za lastni vektor  $z_k$ :

```
for k = 0, 1, ...
    sigma_k = p(z_k, A)
    reši (A - sigma_k I) y_(k+1) = z_k
    z_(k+1) = y_(k+1) / ||y_(k+1)||
```

**QR iteracija:** Na začetku reduciramo  $A$  na tridiagonalno (= zg. Hess). Izvajamo QR iteracijo z enojnimi premiki, ker so vse lv realne. Stane  $30n + O(1)$  operacij in  $n + O(1)$  kv. korenov.

### Bisekcija

Lahko ugotovimo, koliko je lastnih vrednosti, ki so manjše ali enake  $x$ . To vodi v bisekcijo, s pomočjo katere izračunamo eno samo lastno vrednosti. Pri določanju števila lastnih vrednosti pomaga Sturmovo zaporedje.

**Sturmovo zaporedje** Matrika  $T$  je tridiagonalna ( $\text{diag}(a_1, \dots, a_n) + \text{diag}(b_1, \dots, b_{n-1}, 1) + \text{diag}(b_1, \dots, b_{n-1}, -1)$ )  
 $f_0(\lambda) = 1, f_1(\lambda) = a_1 - \lambda, f_{k+1}(\lambda) = (a_{k+1} - \lambda)f_k(\lambda) - b_k^2 f_{k-1}(\lambda)$

Zapišemo zaporedje  $f(x)$ , preštejemo kolikokrat se predznak zamenja (+ 0 - in - 0 + šteje za eno zamenjavo, če je 0 na koncu ne upoštevamo kot zamenjavo). Kolikor je menjav predznaka, toliko je lastnih vrednosti na  $(-\infty, x]$ .

## Deli in vladaj

Tridiagonalno simetrično matriko  $T$  napišemo kot  $T = [T_1, 0; 0, T_2] + \rho vv^T$ ,  $\rho = b_m$  in  $v = e_m + e_{m+1}$  (razdelimo na dva kosa in odštejemo  $b_{mm}$ ). Rekurzivno poračunamo lastne vrednosti manjših dveh podmatrik.  $T_1 = Q_1 D_1 Q_1^T$ ,  $T_2 = Q_2 D_2 Q_1^T$ , da poračunamo lastne vrednosti  $T$  moramo rešiti sekularno enačbo  $1 + \rho \sum_{i=1}^n \frac{u_i^2}{a_i - \lambda} = f(\lambda) = 0$ . Aproximiramo z racionalno funkcijo.

## Jacobijeva iteracija

Pomnožimo z rotacije z leve in z desne, da ubijemo največjega, ali pa vse po vrsti, ali pa tiste ki so nad nekim pragom.

## Posplošeni problem lastnih vrednosti

Množico vseh matrik oblike  $A - \lambda B$  imenujemo matrični šop. Karakteristični polinom šopa  $(A, B)$  je  $p(\lambda) = \det(A - \lambda B)$ . Če je  $p$  identično enak 0, je šop singularen, sicer je regularen. Če je šop regularen in velja  $Ax = \lambda Bx$  za nek  $x \neq 0$ , je  $\lambda$  lastna vrednost in  $x$  desni lastni vektor. Če za regularen šop velja  $Bx = 0$  za nek  $x \neq 0$  je  $\lambda = \infty$  lastna vrednost šopa in  $x$  pripadajoči desni lastni vektor. Simetrično velja za leve lastne vektorje.

Če je karakteristični polinom šopa  $(A, B)$  stopnje  $m \leq n$  ima šop  $m$  lastnih vrednosti, ki so rešitve  $p(\lambda) = 0$  in neskončno lastno vrednost z večkratnostjo  $n - m$ .

Če je  $B$  nesingularna, so vse lastne vrednosti končne in so enake lastnim vrednostim matrik  $B^{-1}A$  in  $AB^{-1}$ . Neskončna lastna vrednost se pojavi, ko je  $B$  singularna, in njena večkratnost je enaka  $\dim(\ker(B))$ . Če je  $A$  singularna, si lastne vrednosti šopa enake recipročnim lastnim vrednostim  $A^{-1}B$  in  $BA^{-1}$  (lastna vrednost 0 pomeni, da ima šop lastno vrednost  $\infty$ ).

Za regularen šop obstajata matriki  $Q, Z$ , da je  $Q^H(A - \lambda B)Z = S - \lambda T$ , kjer sta  $S$  in  $T$  trikotni matriki. Lastne vrednosti so  $s_{ii}/t_{ii}$ . To vodi v **QZ iteracijo**:  $A$  in  $B$  najprej reduciramo na zg. Hess.  $B$  reduciramo s  $QR$  razcepom na zg. trikotno. Potem popravljamo  $A$  in hkrati nazaj  $B$ .

$$A = \begin{bmatrix} * & * & * & * \\ * & * & * & * \\ \boxed{*} & * & * & * \\ \boxed{*} & * & * & * \end{bmatrix} \xrightarrow{R_{34}^T} \begin{bmatrix} * & * & * & * \\ * & * & * & * \\ * & * & * & * \\ * & * & * & * \end{bmatrix} \xrightarrow{\cdot R_{34}^T} \begin{bmatrix} * & * & * & * \\ \boxed{*} & * & * & * \\ \boxed{*} & * & * & * \\ * & * & * & * \end{bmatrix} \xrightarrow{R_{23}^T}$$

$$B = \begin{bmatrix} * & * & * & * \\ & * & * & * \\ & & * & * \\ & & & * \end{bmatrix} \xrightarrow{R_{34}^T} \begin{bmatrix} * & * & * & * \\ & * & * & * \\ & & * & * \\ & & \boxed{+} & \boxed{*} \end{bmatrix} \xrightarrow{\cdot R_{34}^T} \begin{bmatrix} * & * & * & * \\ & * & * & * \\ & & * & * \\ & & & * \end{bmatrix} \xrightarrow{R_{23}^T}$$

Kasneje izvajamo dvojni premik, podobno kot pri QR množimo najprej s  $\tilde{P}$ , ki ima prvi stolpec enak  $N_k$  zgrajena iz matrike  $A_k B_k^{-1}$ . Potem množimo z leve s  $3 \times 3$  Hausholderjevimi zrcaljenji, in z desne popravimo grbo (rabimo več kot en korak).

## Nelinearni problemi lastnih vrednosti

$T(\lambda)$  je neka kvadratna matrika, elementi so gladke funkcije  $\lambda$ . Če je  $y^H T(\lambda) = 0$  za nek  $\lambda$ , je to lastni par. Problem je regularen če je  $T \not\equiv 0$ . Kvadratični problem  $T(\lambda) = \lambda^2 M + \lambda C + K$  lahko lineariziramo v  $[0, N; -K, -C] - \lambda[N, 0; 0, M]$ .

Tak sistem dobimo pri **nihanju**:

Za primer lastnih frekvenc nihanja  $|-//k_1//-[m_1]-//k_2//-[m_2]-//k_3//-[m_3]-//k_4//[-]$  zapišemo

$M = \text{diag}(m_1, m_2, m_3)$ ,

$K = \begin{bmatrix} k_1 + k_2 & -k_2 & & \\ -k_2 & k_2 + k_3 & -k_3 & \\ & -k_3 & k_3 + k_4 & \end{bmatrix}$  rešujemo sistem  $\omega^2 M y + K y = 0$ , kar lahko prevedemo na  $-M^{-1} K y = \lambda y$ ,  $\lambda = \omega^2$