

1. KONVEKSNOST

$A \subseteq \mathbb{R}^n$ je konveksna, če za vsaka $x, y \in A$ in vsak $\lambda \in [0, 1]$ velja: $\lambda x + (1 - \lambda)y \in A$.

Naj bodo $k \in \mathbb{N}, x_1, \dots, x_k \in \mathbb{R}^n, \lambda_1, \dots, \lambda_k \in \mathbb{R}$. Potem je *konveksna kombinacija* $\sum_{i=1}^k \lambda_i x_i$, pri čemer je $\sum_{i=1}^k \lambda_i = 1$.

Lastnosti konveksnih množic:

- A, B konveksni $\implies A \cap B$ konveksen.
- $\forall \lambda \in \mathcal{J} : A_\lambda$ konveksna $\implies \cap_{\lambda \in \mathcal{J}} A_\lambda$ konveksna.
- A, B konveksni $\implies A + B = \{x + y | x \in A, y \in B\}$ konveksna (vsota Minkowskega).
- Konveksna množica vsebuje vse konveksne kombinacije svojih elementov.
- $A \subseteq \mathbb{R}^n \iff \forall \alpha, \beta \geq 0$ velja: $\{\alpha x + \beta y | x, y \in A\} = \{(\alpha + \beta)z | z \in A\}$.
- $A \subseteq \mathbb{R}^m, B \subseteq \mathbb{R}^n$ konveksni $\implies A \times B$ konveksna.
- $A \times B$ konveksna in A, B neprazni $\implies A, B$ konveksni.
- $A, B \subseteq \mathbb{R}^n$ konveksni $\implies A + B$ konveksna (vsota Minkowskega).
- $\mathcal{C}(A + B) = \mathcal{C}(A) + \mathcal{C}(B)$ (vsota Minkowskega).
- $A, B \subseteq \mathbb{R}^n \implies \mathcal{C}(\mathcal{C}(A) \cup \mathcal{C}(B)) = \mathcal{C}(A \cup B)$.

$A \subseteq \mathbb{R}^n$. Konveksna ovojnica množice A je $\mathcal{C}(A) = \cap \{K \subseteq \mathbb{R}^n | K \text{ konveksna}, A \subseteq K\}$.

Lastnosti konveksnih ovojnic:

- $A \subseteq \mathcal{C}(A)$.
- $\mathcal{C}(A)$ je konveksna.
- $A \subseteq B, B$ konveksna $\implies \mathcal{C}(A) \subseteq B$.
- Konveksna ovojnica množice A je najmanjša konveksna množica, ki vsebuje A .
- $\mathcal{C}(A)$ je množica vseh konveksnih kombinacij elementov množice A .
- A konveksna $\iff \mathcal{C}(A) = A$.
- $\mathcal{C}(A \cap B) \subseteq \mathcal{C}(A) \cap \mathcal{C}(B)$.
- $A \subseteq \mathbb{R}^n$ konveksna $\implies Cl(A)$ konveksna.
- $A \subseteq \mathbb{R}^n$ konveksna $\implies Int(A)$ konveksna.
- Če $A \subseteq B$, tedaj $\mathcal{C}(A) \subseteq \mathcal{C}(B)$.

Funkcija $f : \mathbb{R}^n \rightarrow \mathbb{R}$ je konveksna, če za poljubna $x, y \in \mathbb{R}^n$ in $\lambda \in [0, 1]$ velja: $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$.

Lastnosti konveksnih funkcij:

- $A \in \mathbb{R}^{n \times n}$ simetrična. Kvadratna forma $F : \mathbb{R}^n \rightarrow \mathbb{R}$ s predpisom $F(x) = \langle Ax, x \rangle$. F je konveksna funkcija $\iff A$ pozitivno semidefinitna.
- $A \subseteq \mathbb{R}^n$ konveksna, $f, g : A \rightarrow \mathbb{R}$ konveksni $\implies f + g : A \rightarrow \mathbb{R}$ konveksna.
- $A \subseteq \mathbb{R}^n$ konveksna, $g : A \rightarrow \mathbb{R}$ konveksna, $f : \mathcal{C}(g(A)) \rightarrow \mathbb{R}$ konveksna, nepadajoča $\implies f \circ g : A \rightarrow \mathbb{R}$ konveksna.
- $A \subseteq \mathbb{R}^n$ konveksna, $f : A \rightarrow \mathbb{R}$ konveksna, $x_1, x_2 \in A, x_1 \neq x_2, x \in \lambda x_1 + (1 - \lambda)x_2, x$ različen od x_1, x_2 . Potem velja:

$$\frac{f(x) - f(x_1)}{\|x - x_1\|} \leq \frac{f(x_2) - f(x_1)}{\|x_2 - x_1\|} \leq \frac{f(x_2) - f(x)}{\|x_2 - x\|}.$$

- $A \subseteq \mathbb{R}^n$ konveksna, $f : A \rightarrow \mathbb{R}$ konveksna funkcija $\implies f^{-1}(-\infty, a)$ konveksna množica za vsak $a \in \mathbb{R}$.
- $A \subseteq \mathbb{R}^n$ konveksna, $f, g : A \rightarrow \mathbb{R}$ konveksni funkciji $\implies \max\{f, g\} : A \rightarrow \mathbb{R}$ konveksna funkcija.

$A \subseteq \mathbb{R}^n$ konveksna. Točka $a \in A$ je *ekstremna (skrajna) točka* množice A , če $A \setminus \{a\}$ konveksna.

$A \subseteq \mathbb{R}^n$ je *konveksni stožec*, če za vse $x, y \in A$ in $\lambda, \mu \geq 0$ velja: $\lambda x + \mu y \in A$.

Za $a_1, \dots, a_k \in \mathbb{R}^n$ označimo $\mathcal{S}(a_1, \dots, a_k) = \left\{ \sum_{i=1}^k \lambda_i a_i | \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1 \right\}$. To je konveksni stožec, ki ga razpenjajo a_1, \dots, a_k .

$K \subseteq \mathbb{R}^n$ je *konveksni polieder*, če obstaja $m \in \mathbb{N}, A \in \mathbb{R}^{m \times n}$ in $b \in \mathbb{R}^m$, tako da je $K = \{x \in \mathbb{R}^n | Ax \leq b\}$.

Konveksni polieder v \mathbb{R}^n je presek končno mnogo zaprtih polprostorov v \mathbb{R}^n .

K konveksni polieder $\iff K = A + B$, kjer sta A konveksna ovojnica končne množice in B konveksni stožec $\mathcal{S}(a_1, \dots, a_k)$.

Polieder $Ax \leq b$ vsebuje premico, če rang matrike A ni maksimalen.

2. LINEARNO PROGRAMIRANJE

Linearni program (LP) v standardni obliki je optimizacijska naloga oblike:

- Podatki: $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, c \in \mathbb{R}^n$
- Iščemo: $\max \langle c, x \rangle$ pri pogojih $Ax \leq b, x \geq 0$.

Slovar \mathcal{S} je dopusten, če so prosti členi v \mathcal{S} nenegativni.

Dopustna rešitev x je bazna dopustna rešitev (bdr), če obstaja dopusten slovar \mathcal{S} , tako da velja:

- (1) vrednosti nebaznih spremenljivk v x so 0,
- (2) vrednosti baznih spremenljivk v x so enake ustreznim prostim členom v \mathcal{S} .

sx metoda:

Izbira *vstopajoče* spremenljivke: katerakoli spremenljivka v funkcionalu pod črto s pozitivnim koeficientom. (izrazimo iz enačbe, v kateri je izstopajoča spremenljivka bazna)

Izbira *izstopajoče* spremenljivke: Tista, ki najbolj omejuje povečanje vstopajoče spremenljivke.

Naj bo \mathcal{S} dopusten slovar, v katerem imajo vse spremenljivke v funkcionalu pod črto koeficiente manjše ali enake 0.

Potem je bdr x^* , ki jo določa \mathcal{S} , optimalna.

Naj bo \mathcal{S} dopusten slovar s funkcionalom $\langle c, x \rangle = z = v^* + \sum_{k=1}^{n+m} \tilde{c}_k x_k$, kjer so vsi $\tilde{c}_k \leq 0$. Potem je x optimalna rešitev natanko tedaj, ko:

- (1) x zadošča \mathcal{S} ,
- (2) $x \geq 0$,
- (3) $x_k = 0$ za vse tiste k , za katere je $\tilde{c}_k < 0$.

Naj bo Π LP. Potem sta $D(\Pi)$, $Opt(\Pi)$ konveksna poliedra v \mathbb{R}^n .

Bdr x je *izrojena*, če ima v njej vsaj ena bazna spremenljivka vrednost 0.

Če nobena bazna spremenljivka ne omejuje povečanja vstošajoče spremenljivke, je LP *neomejen*.

DVOFAZNA SX METODA:

I. FAZA (poiščemo začetno bdr ali pa ugotovimo, da LP nedopusten) - prvotni LP je dopusten natanko tedaj, ko ima pomožni LP optimalno vrednost 0.

Pravila:

- (1) Na prvem koraku v bazo vstopi x_0 , izstopi pa bazna spremenljivka z najmanjšo vrednostjo.
- (2) V nadaljnjih korakih:
 - (a) Če je x_0 kandidatka (na kakšnem koraku) za izstopajočo spremenljivko, jo izberemo.
 - (b) Če dobimo funkcional z vrednostjo 0, končamo.

Začetnemu slovarju prištejemo v vsaki vrstici x_0 , novi funkcional je $w = -x_0$.

II. FAZA

V zadnjem slovarju I. faze izpustimo vse člene, ki vsebujejo x_0 . Funkcional nadomestimo s prvotnim funkcionalom, kjer vse bazne spremenljivke izrazimo z nebaznimi (s pomočjo slovarja).

Tako dobimo dupusten slovar za prvotni LP.

PREPREČITEV NESKONČNE SX METODE

1. Kadar imamo več kandidatov za vstopajočo spremenljivko, izberemo tisto z minimalnim indeksom. Enako za izstopajočo.

PREVEDBA NA ENAKOVREDEN LP V STANDARDNI OBLIKI:

$opt \langle c, x \rangle + d$ pri pogojih $Ax \leq b$, $A'x \geq b'$, $A''x = b''$, $x_i \geq 0$ za nekatere i .

- (1) d lahko izpustimo
- (2) $\min \langle c, x \rangle = -\max \langle -c, x \rangle$
- (3) $A'x \geq b' \iff -A'x \leq -b'$
- (4) $A''x = b'' \iff A''x \leq b''$, $-A''x \leq -b''$
- (5) Če x_i nima pogoja nenegativnosti, jo razcepimo:

$$x_i = x_i^+ - x_i^-, x_i^+, x_i^- \geq 0.$$

Za vsak LP velja:

- (1) je bodisi nedopusten bodisi neomejen bodisi ima optimalno rešitev,
- (2) če ima dopustno rešitev, ima bazno dopustno rešitev,
- (3) če ima optimalno rešitev, ima bazno optimalno rešitev.

MINIMIZACIJA VSOTE ABSOLUTNIH VREDNOSTI:

Poišči $y_i, i = 1, \dots, m$, ki minimizira

$$\sum_{i=1}^p \left| \sum_{j=1}^m y_i b_{ij} - c_j \right|$$

pri splošnih linearnih pogojih.

Uvedemo p novih spremenljivk y_{m+1}, \dots, y_{m+p} . y_{m+j} je zgornja meja j -tega člena, ki minimizira $\sum_{i=1}^p y_{m+i}$. Pogoji za y_{m+j} :

$$y_{m+j} \geq \sum_{i=1}^m y_i b_{ij} - c_j, \quad y_{m+j} \geq -\left(\sum_{i=1}^m y_i b_{ij} - c_j\right)$$

MINIMIZACIJA MAKSIMUMA ABSOLUTNIH VREDNOSTI:

Poišči y , ki minimizira $\max_{1 \leq j \leq p} \left| \sum_{i=1}^m y_i b_{ij} - c_j \right|$ pri splošnih linearnih pogojih.

Dodamo novo spremenljivko μ :

$$\left| \sum_{i=1}^m y_i b_{ij} - c_j \right| \leq \mu \quad \forall j$$

in minimiziramo μ pri pogojih

$$\sum_{i=1}^m y_i b_{ij} - c_j \leq \mu \quad \text{in} \quad -\left(\sum_{i=1}^m y_i b_{ij} - c_j\right) \leq \mu.$$